

灵山小向导·灵曦——景区导览服务 AI 数字人项目说明书

第十五届中国软件杯 A5「景区导览服务 AI 数字人」参赛作品材料

参赛学校：[请填写学校名称]

团队名称：[请填写团队名称]

团队成员：[请填写成员与分工]

指导教师：[请填写指导教师]

文档版本：V1.0 (2026-07-19)

目录

1. 项目摘要

2. 赛题要求映射

2.1 游客交互侧

2.2 管理后台侧

2.3 非功能要求

3. 用户与业务场景

3.1 游客角色

3.2 管理者角色

3.3 核心体验旅程

4. 产品功能设计

4.1 游客端

4.2 管理端

5. 总体架构

5.1 服务边界

6. 核心技术设计

6.1 可靠景区 RAG

6.2 低延迟语音数字人

6.3 多模态识景与情绪分析

6.4 按需 GPU 与稳定性

7. 数据设计与运营闭环

7.1 核心数据

7.2 当前真实运营快照

8. 测试与验证

8.1 关键指标

8.2 稳定性与安全验证

9. 创新点

10. 部署与使用

10.1 环境要求

10.2 启动

10.3 访问

11. 项目边界与后续规划

11.1 当前边界

11.2 演进路线

12. 团队介绍（提交前补充）

13. 答辩展示建议

14. 提交清单

1. 项目摘要

“灵山小向导·灵曦”是一套面向游客与景区管理者的 AI 数字人导览系统。游客可通过 文字、麦克风、图片、兴趣偏好和位置信息与数字人交互，获得景点讲解、连续追问、个性化路线、拍照识景和弱定位导览；系统将大模型回答按完整语义句流式送入语音合成 和 Wav2Lip 口型驱动，让数字人尽快自然开口。

管理端提供真实交互数据概览、热门咨询、知识库维护、数字人名称/形象/音色配置、游客感受度报告以及历史游客行为分析。系统以本地 BGE-M3 + FAISS 景区知识库约束 GLM 回答，形成“游客服务—反馈采集—运营洞察—知识更新”的持续优化闭环。

本项目针对赛题提出的四类核心痛点给出对应方案：

赛题痛点	产品应对
旺季导游资源稀缺	7×24 小时在线数字人，多终端访问，统一知识口径
传统录音导览单向	支持文字、语音、图片、位置和连续追问
缺乏情感连接	真人数字人口型、自然语音、情绪状态和轻量模式降级
管理者存在数据盲区	实时运营看板、热门主题、情绪趋势、满意度与服务建议

2. 赛题要求映射

2.1 游客交互侧

赛题基本功能	本项目实现	当前状态
语音与文本输入	HTTPS 麦克风录音、GLM-ASR、文本问答统一进入 RAG	已实现
语音、表情、口型同步回答	GLM-TTS + LiveTalking/Wav2Lip + WebRTC；Live2D 轻量降级	已实现
景区历史文化问答	BGE-M3 + FAISS 检索官方资料，回答附引用并约束拒答	已实现
个性化路线	历史、自然、亲子三类偏好生成不同路线与讲解重点	已实现
更复杂现实定位	GPS、景点码、Wi-Fi/二维码接口和手动选择多级降级	已实现演示适配层

2.2 管理后台侧

赛题基本功能	本项目实现	当前状态
知识库管理	登录后上传/更新/删除 DOCX、TXT、Markdown，自动重建索引	已实现
数字人形象管理	配置显示名称、已安装头像、音色和默认表情	已实现
游客感受度报告	HumanOmni 七类情绪、文本倾向、方面分析和显式评分分别展示	已实现，支持降级
数据大屏	今日/七日游客、累计问答、平均响应、热门主题、服务建议	已实现

说明：当前后台只展示真实可操作配置，不提供无法生效的“服装风格”入口。服装扩展需 通过新增数字人模型包实现，避免在比赛演示中展示虚假能力。

2.3 非功能要求

赛题要求	验证结果
至少一个多模态大模型	GLM-4V 识景；HumanOmni 音视频情绪；GLM-ASR/GLM-TTS 语音链路
本地景区知识库	BGE-M3 + FAISS，当前 97 个知识片段、1024 维向量
事实问答准确率不低于 90%	标准事实题 15/15，实测 100%
语音问答延迟小于 5 秒	单次“语音结束→首个非静音数字人音频帧”实测 3373ms
系统稳定、避免长时间无响应	服务健康检查、watchdog、超时、回退和按需 GPU 生命周期

3. 用户与业务场景

3.1 游客角色

- 1. **首次到访游客**：不了解景区结构，希望获得入园后的顺路路线。
- 2. **亲子家庭**：关注轻松、有趣、少折返和休息点。
- 3. **文化兴趣游客**：希望深入了解佛教文化、建筑和历史背景。
- 4. **自由行游客**：不愿跟团，希望随时提问、拍照识景和连续追问。
- 5. **特殊环境游客**：GPS 或网络不稳定时，需要二维码或手动定位降级。

3.2 管理者角色

- 1. 运营人员查看实时服务量、热门咨询和响应情况。
- 2. 内容人员更新讲解资料和常见问答，无需修改程序。
- 3. 服务主管查看游客情感、满意度和重点投诉方面。
- 4. 决策人员结合 140447 条历史游客记录进行客群与景点分析。

3.3 核心体验旅程

- 入园打开网页/Android App
 - 选择历史/自然/亲子兴趣
 - 文字或麦克风提问
 - 本地知识库检索与引用
 - 数字人语音、口型、表情同步讲解
 - 拍照识景 / 获取位置 / 生成路线
 - 提交评分与建议
 - 管理后台形成运营洞察
 - 更新知识库和服务策略

4. 产品功能设计


4.1 游客端

- **景区问答**：支持事实问题、文化故事、游览建议和会话追问。
- **麦克风交互**：浏览器通过 HTTPS 获取权限，录音完成后自动识别并进入统一问答。
- **数字人讲解**：数字人按语义句开始播报，不等待整段文字生成完成。
- **个性化路线**：基于游客兴趣、时间和当前位置组织路线及讲解重点。
- **拍照识景**：视觉模型先识别场景，再由本地知识库校准讲解，降低景点幻觉。
- **弱定位导览**：支持当前位置、景点码和手动选择；定位失败仍可继续使用。
- **满意度反馈**：游客可对具体景区/景点提交 1-5 分与文字建议。
- **Android 端**：网页封装 APK，统一复用 HTTPS 麦克风、问答和数字人服务。

4.2 管理端

- **数据概览**：今日游客、近七日游客、累计问答、平均响应和热门主题。
- **知识库管理**：官方资料只读，管理员资料可上传、更新、删除并触发索引重建。
- **数字人管理**：配置显示名称、已安装形象、TTS 音色和默认表情，新会话生效。
- **游客感受度**：区分七类音视频情绪、文本倾向、方面和显式满意度，展示分析模式。
- **历史游客洞察**：分析 2025 年 140447 条访问记录、50000 名游客和 152 个景点。
- **智能建议**：根据真实咨询与反馈证据生成服务优化建议，不伪造满意度数据。

5. 总体架构



5.1 服务边界

服务	端口	作用	暴露范围
游客 HTTP/API	8001	文字访问、开放 API、静态页面	游客
游客 HTTPS + TURN/TCP	8443	麦克风、WebRTC 与公网访问	游客
LiveTalking	8010	数字人会话、音频队列与口型驱动	仅内部
RAG	8020	BGE-M3、FAISS、GLM 问答	仅本机
管理后台	8444	数据、知识库、数字人和报告	管理员

6. 核心技术设计

6.1 可靠景区 RAG

1. 官方 DOCX、TXT、XLSX 和管理员文档按标题与段落切片。
2. BGE-M3 将知识片段编码为 1024 维归一化向量。
3. FAISS `IndexFlatIP` 执行余弦相似度检索。
4. 命中景点名称或别名后先做元数据过滤，减少兄弟景点信息串扰。
5. 系统提示约束数字、日期、重量等事实必须来自检索上下文。
6. 资料不足时明确回答“当前知识库未覆盖”，避免大模型编造。
7. 引用 ID、来源和小节随回答返回，便于评委和管理员追溯。

RAG embedding 采用“CPU 常驻协调器 + 按需 GPU 子进程”。平时 BGE-M3 只占 CPU 内存；检索时从 0-3 号 GPU 中选择空闲卡，GPU worker 空闲 180 秒后退出，从而彻底释放 CUDA 上下文。连续问答复用同一 worker，兼顾首轮速度与资源利用率。

6.2 低延迟语音数字人

浏览器录音

- GLM-ASR
- RAG/GLM 流式文本
- 按句号、问号等语义边界切分
- GLM-TTS 流式 PCM 合并成完整语义段
- WAV 上传 LiveTalking
- Wav2Lip FP16 推理
- WebRTC 音视频

系统不按固定短字数粗暴切分，而是优先等待完整语义句；同一语义段的 PCM 块合并后再进入数字人，避免每个提供方分块重复重采样、淡入淡出和吞字。再次提问时会取消旧播报队列，避免新旧答案重叠。

6.3 多模态识景与情绪分析

- 图片由 GLM-4V 识别，结果再次进入景区 RAG 校准。
- 游客授权后，HumanOmni 输出 angry、disgust、fear、happy、neutral、sad、surprise。
- 文本模块提取讲解内容、回答准确性、响应速度、路线、票价、餐饮和交通等方面。
- 七类情绪、文本倾向和 1-5 分满意度分别存储，不把历史满意度伪装成情绪标签。
- 情绪分析异步执行，失败时明确标记文本降级，不阻塞实时问答。
- 默认在分析后删除原始媒体，仅保留结构化结果。

6.4 按需 GPU 与稳定性

- LiveTalking 权重在 CPU/RAM 待机，浏览器建立 WebRTC 后自动选择空闲 GPU。
- 页面关闭或心跳失效后，数字人进程退出以释放 CUDA 上下文。
- RAG embedding 检索后保留 GPU 180 秒，连续问答直接复用；随后 worker 退出。
- 本地 Qwen2-7B 仅选择本地模型路线时加载，空闲后自动卸载。
- RAG、API、LiveTalking 和本地模型均有健康检查和 watchdog。
- LiveTalking 不可用时游客端回退到 Live2D 轻量模式，文字问答仍可继续。

7. 数据设计与运营闭环

7.1 核心数据

数据	用途
chat_logs	会话、角色、内容、引用、情绪和响应时间
feedback	景区/景点、1-5 分、意见和时间
emotion_events	七类概率、文本倾向、方面、模式和错误
avatar_settings	数字人名称、形象、音色和表情
tourism_visits	赛题历史游客行为原始字段，共 140447 行
FAISS + metadata	97 个知识片段的向量与来源元数据

7.2 当前真实运营快照

采集时间：2026-07-19。

指标	当前值
今日服务游客	176
近 7 日游客	183
累计问答	235
平均响应	3182ms
热门主题第一名	灵山大佛（117 次）
路线/定位相关咨询	11 次
历史数据记录	140447
历史独立游客	50000
历史景点数	152
HumanOmni 已完成任务	35

这些数字来自 SQLite 实时交互记录和赛题 XLSX 导入结果。当前暂无足够游客主动评分，后台显示“暂无”而不是生成虚假满意度。

8. 测试与验证

8.1 关键指标

测试项	结果	结论
标准事实题	15/15, 100%	超过赛题 90% 要求
语音结束→首个非静音数字人音频	3373ms	满足小于 5 秒目标
质量优先热链路首响中位数	3618ms	三轮均收到完整非静音音频
LLM 首 token	535ms	流式生成有效
首 token→首响	3121ms	语音与数字人阶段可量化
API 回归	35 passed	核心接口通过
语音回归	10 passed	PCM 合并与数字人队列通过
RAG pipeline/session	9 passed	会话、检索与流式处理通过

性能数字均对应本机热链路测试。公网环境会叠加页面加载、TURN 网络 RTT、首次 GPU 迁移和云模型波动；答辩时应说明测试口径，不把局域网结果包装成所有网络环境保证值。

8.2 稳定性与安全验证

- 模型密钥只保存在服务端，不下发浏览器。
- RAG 与 LiveTalking 只监听内部地址，由网关代理。
- 管理后台采用独立端口、签名会话 Cookie 和来源校验。
- 知识文档修改、索引重建只允许已登录管理员操作。
- 文件类型、大小、会话长度和历史轮数均有限制。
- 多模态原始媒体默认分析后删除。

9. 创新点

1. **首句即说的跨模型流水线**：将串行“全文完成后播报”改造成 LLM、TTS、数字人按语义句衔接。
2. **视觉结果二次 RAG 校准**：通用视觉模型负责识别，本地资料负责最终景点事实讲解。
3. **事实级可追溯与拒答**：引用资料、景点元数据过滤、会话边界和缺失信息拒答共同降低幻觉。
4. **按需 GPU 生命周期**：数字人、RAG embedding 和本地 LLM 分别按需启用，闲时释放显存。
5. **位置多级降级**：GPS 不可用时仍可通过景点码、Wi-Fi/二维码适配层或手动选择继续导览。
6. **实时与历史双层洞察**：把当日互动和赛题 14 万条历史记录放在同一运营决策界面。
7. **证据化感受度报告**：保留模态、置信度、降级方式和原始方面，不混淆情绪与满意度。

10. 部署与使用

10.1 环境要求

- Linux、NVIDIA GPU、CUDA 12.x
- `ccc` Conda 环境：FastAPI、LiveTalking、语音/视觉客户端
- `softcup` Conda 环境：BGE-M3、FAISS、HumanOmni
- 智谱 API Key，仅存放在服务端文件或环境变量

10.2 启动

```
cd /home/gmn/codes/cup
bash deploy/start_livetalking.sh
bash deploy/start_api.sh
```

10.3 访问

```
游客文字端: http://<服务器IP>:8001/
游客麦克风端: https://<服务器IP>:8443/
景区管理后台: https://<服务器IP>:8444/admin
接口文档: http://<服务器IP>:8001/docs
```

麦克风需要 HTTPS 或 localhost 安全上下文。首次使用自签名证书时，需在浏览器中接受 证书提示。实际比赛部署应替换为可信域名证书。

11. 项目边界与后续规划

11.1 当前边界

- 当前使用已安装的 Wav2Lip 真人头像；新增外观需要制作新的头像模型包。
- GPS/Wi-Fi 为演示适配层，生产环境需接入真实坐标、地图和锐捷网络位置能力。
- 默认问答、语音和视觉依赖云端 GLM，公网波动会影响端到端时延。
- 自建 HTTPS 当前可使用自签名证书，正式运营需配置可信证书和域名。
- 高并发数字人需要进一步增加 GPU 配额、会话队列和容量压测。

11.2 演进路线

1. 接入景区 POI、室内 Wi-Fi 定位和拥挤度，动态规划路线。
2. 增加多景区租户、方言音色、儿童模式和无障碍模式。
3. 建立数字人头像制作流水线，支持景区 IP 与服装模型包。
4. 引入边缘节点缓存与模型量化，提高旺季并发并降低云服务成本。
5. 建立真实游客授权评测集，持续评估事实准确率、自然度与情绪识别。

12. 团队介绍（提交前补充）

角色	姓名	主要职责
队长 / 产品架构	【待填写】	产品方案、总体架构、答辩统筹
大模型与 RAG	【待填写】	知识库、检索、提示词与评测
数字人与语音	【待填写】	ASR/TTS、LiveTalking、WebRTC、延迟优化
前后端与数据	【待填写】	游客端、管理后台、数据分析与部署
指导教师	【待填写】	技术指导、项目管理与质量审查

13. 答辩展示建议

建议按以下顺序进行 7-8 分钟现场展示：

1. 30 秒说明景区痛点与产品定位。
2. 现场语音提问“灵山大佛有多高、用了多少铜”。
3. 连续追问并展示引用、数字人口型和新问题打断。
4. 展示亲子/历史路线、拍照识景和弱定位。
5. 提交一次反馈，在后台刷新实时数据。
6. 上传一份知识文档并验证新知识立即生效。
7. 展示测试页：15/15 准确率、3373ms 首响和健康状态。
8. 以“让每位游客拥有专属导游，让每次互动成为运营依据”收束。

14. 提交清单

- ☐ 产品源代码或可执行文件
- ☐ 部署与使用手册
- ☐ 总体设计文档
- ☐ 产品方案介绍 PPTX
- ☐ 不超过 7 分钟的 MP4 演示视频
- ☐ 团队、学校、指导教师信息已补充
- ☐ 所有性能数据注明测试环境、日期与口径
- ☐ 演示前完成 HTTPS、麦克风、GPU、RAG、管理后台健康检查