

灵山小向导·灵曦——软件工程文档

项目名称：景区导览服务 AI 数字人系统

文档类型：软件需求与设计说明

更新日期：2026-08-01

1. 文档概述

1.1 编写目的

本文档说明“灵山小向导·灵曦”的软件需求、系统架构、核心流程、数据结构、接口、部署和测试方案，作为开发、联调、测试与后续维护的统一依据。

1.2 系统范围

系统包含游客端、景区管理端、导览 API、个性化路线与地图展示、RAG 服务、语音与视觉模型接口、数字人服务、情绪分析服务和本地数据存储。系统提供基于来源点位的游览顺序地图和第三方分段 步行导航入口，但不负责票务交易、园内道路级路径计算、实时路况、逐向导航或景区硬件控制。

1.3 术语

术语	说明
RAG	检索增强生成，先检索景区资料，再生成回答
ASR / TTS	语音识别 / 语音合成
FunASR	本地中文语音识别服务，供两条 Qwen 问答路线使用
GLM-TTS	语音合成模型；系统同时接入云端 API 和本地开源部署
SSE	服务端事件，用于流式返回模型文本
WebRTC	数字人实时音视频传输协议
LiveTalking	数字人口型驱动与音视频服务
HumanOmni	音视频情绪分析模型
Leaflet	游客端本地加载的开源交互式地图库
高德地图（AMap）	当前路线页在线底图和外部分段步行导航服务
OpenStreetMap（OSM）	部分公开近似点位的数据来源；旧版同源瓦片代理的上游，不是当前路线页主底图
WGS-84	来源点位、浏览器 GPS 和路线距离计算使用的经纬度坐标系
GCJ-02	高德底图展示与高德 URI 导航使用的坐标系，由后端从 WGS-84 转换

2. 系统概述

2.1 建设目标

系统为游客提供文字问答、语音问答、数字人讲解、可视化个性化路线、拍照识景、定位辅助和 满意度反馈；为景区管理人员提供知识维护、数字人配置、服务统计和游客感受度分析。

2.2 用户角色

角色	主要职责
游客	提问、听取讲解、设置路线偏好、查看地图与分段导航、识别景点、提交反馈
内容管理员	维护景区知识文档并重建索引
运营管理员	查看访问量、热门咨询、响应时间和游客反馈
系统维护人员	启停服务、检查健康状态、管理 GPU 与日志

2.3 系统边界

- 游客端只能访问公开导览接口，不能直接访问管理接口。
- 管理端使用独立登录会话和来源校验。
- RAG 与 LiveTalking 只作为内部服务，由 FastAPI 网关调用。
- 云端 GLM 问答路线通过服务端 API 调用 GLM-ASR 和云端 GLM-TTS，密钥不下发到浏览器。
- 轻量 Qwen3-1.7B 和完整 Qwen3-8B 问答路线配套使用本地 FunASR 与本地开源 GLM-TTS；本地语音服务只监听环回地址，由 FastAPI 调用。
- 知识库回答只以已导入的景区资料为事实依据。
- 只有具备 WGS-84 坐标及来源/测绘状态的景点才进入地图规划；公开近似点不得标记为现场实测。
- Leaflet 在本地静态资源中加载；路线点位由后端从 WGS-84 转换为 GCJ-02 后叠加到高德在线 底图，并生成高德步行导航链接；地图与导航均不可用时仍保留文字路线。

3. 需求分析

3.1 功能需求

编号	模块	功能要求
FR-01	景区问答	支持文字提问、连续追问、引用来源和资料不足时拒答
FR-02	语音交互	浏览器录音后按问答路线选择 ASR：云端 GLM 使用 GLM-ASR，两条 Qwen 路线使用本地 FunASR；转写后进入统一问答流程
FR-03	数字人讲解	将回答按完整语义句合成语音；云端 GLM 使用云端 GLM-TTS，两条 Qwen 路线使用本地 GLM-TTS，再驱动口型并通过 WebRTC 播放
FR-04	路线规划	根据景区、2/4/6 小时时长、多选兴趣、同行人群、步行偏好和已确认起点生成路线
FR-05	拍照识景	视觉模型识别图片，再由景区知识库校准讲解
FR-06	定位辅助	支持 GPS、景点码和手动选择，并在定位失败时降级

编号	模块	功能要求
FR-07	游客反馈	对具体景区或景点提交 1–5 分和文字建议
FR-08	管理登录	管理员登录、会话验证和退出
FR-09	知识管理	上传、查看、删除管理员文档并触发索引重建
FR-10	数字人配置	配置显示名称、已安装形象和合成声音；表情由情绪策略实时驱动
FR-11	运营分析	展示游客量、问答量、响应时间、热门主题和反馈
FR-12	感受度分析	保存情绪、文本倾向、方面、置信度和分析状态
FR-13	路线地图	展示编号点位、游览顺序、预计距离/时间、逐站建议、覆盖说明和第三方分段步行导航


3.2 非功能需求

编号	类别	要求
NFR-01	性能	热链路语音问答目标为 5 秒内开始数字人非静音播报
NFR-02	可用性	RAG、本地语音、数字人或情绪模型失败时应明确提示或降级，不阻塞可用的文字问答能力
NFR-03	安全	管理接口鉴权；模型密钥仅在服务端保存；限制文件类型和大小
NFR-04	可维护性	API、RAG、本地语音、数字人和分析模块独立部署，提供健康检查
NFR-05	资源	GPU 模型按需启用，空闲后释放 CUDA 上下文
NFR-06	可追溯性	回答记录引用片段、响应时间、模型路线和会话标识
NFR-07	地图降级	底图或第三方导航不可用时仍展示路线摘要、逐站行程、坐标来源和明确提示
NFR-08	数据真实性	路线点位保留坐标系、来源、测绘状态和预计精度；游览顺序线不得宣传为道路级导航

3.3 系统用例图

系统用例图

游客服务与景区运营两类角色共享同一导览平台



3.4 主要用例


用例	前置条件	主流程	异常处理
景区问答	游客端可访问 API	提交问题→检索知识→流式生成→展示引用	RAG 不可用时返回明确错误
语音数字人问答	HTTPS 麦克风授权成功并已选择模型路线	录音→按路线选择云端/本地 ASR→RAG→按路线选择云端/本地 TTS→数字人口型→WebRTC 播放	语音或数字人不可用时保留文字输入与文字回答
个性化地图路线	景区至少存在一个可核验地图点位	选择景区/时长/兴趣/人群/步行偏好/起点→规划→地图与逐站行程→数字人播报	无点位时返回 422；底图失败时保留文字路线
知识库更新	管理员已登录	上传文档→校验→切片→向量化→重建索引	文件不合法或重建失败时保留旧索引
运营分析	管理员已登录	查询日志、反馈、情绪和历史数据→聚合展示	数据不足时显示“暂无”

4. 系统设计

4.1 总体架构

系统总体架构图

接入层、网关层、智能服务层与数据资产层分层解耦




系统采用分层服务架构。FastAPI 负责对外接口和业务编排；RAG、本地语音网关、本地 GLM-TTS、LiveTalking 和 HumanOmni 作为独立服务，云端 GLM 模型通过服务端 API 接入；路线规划器复用定位模块中可追溯的地图点位，FastAPI 保留 WGS-84 来源坐标并生成 GCJ-02 展示坐标和高德导航链接；游客端使用本地 Leaflet 加载高德在线底图，绘制编号标记和游览顺序线；SQLite、FAISS、文档和模型资源分别管理。

4.2 模块划分

模块	代码位置	职责
导览 API	services/api/app/	会话、问答、语音、视觉、路线、定位、反馈和管理接口
路线规划	services/api/app/route_planner.py	按时间预算、兴趣、人群、步行偏好和距离筛选站点，执行 WGS-84→GCJ-02 转换并生成高德步行导航链接
地图点位	services/api/app/location.py	校验 WGS-84 锚点，输出点位来源、测绘状态、预计精度和地图可用目录
旧版地图瓦片代理	services/api/app/map_tiles.py	兼容旧版 OSM 同源瓦片请求；当前路线页不再使用，后续可与 MAP_TILE_* 配置一并清理
RAG 服务	llm/api.py、llm/rag/	文档切片、向量检索、提示构建、会话和模型生成

模块	代码位置	职责
本地语音服务	services/local_speech/、services/glm_tts/	为两条 Qwen 路线提供 FunASR 转写、本地 GLM-TTS 合成、景区热词和统一音色
数字人服务	LiveTalking/	会话管理、音频队列、口型推理和 WebRTC 输出
情绪分析	services/emotion/	音视频情绪推理、文本降级和结构化结果
管理前端	services/api/static/	登录、知识管理、数字人设置和数据展示
游客前端	services/api/static/index.html、services/api/static/vendor/leaflet.*	路线条件输入、Leaflet + 高德底图、逐站行程、地图降级和数字人播报
部署脚本	deploy/	服务启动、TLS、TURN 和公网转发

4.3 语音问答时序



模型回答采用 SSE 流式返回。`model_route` 控制整条语音链路：`cloud` 使用 GLM-ASR 和 云端 GLM-TTS，`local_lite`、`local` 分别对应两条 Qwen 问答路线，并统一使用本地 FunASR 和本地 GLM-TTS。FastAPI 使用

语义边界切分完整句子，并行衔接 TTS 和 LiveTalking，避免等待 全文完成。新问题到达时取消旧播报队列，防止音频重叠。

4.4 异常与降级

故障	系统处理
RAG 服务不可用	返回 503 和明确错误，不生成无知识依据的答案
LiveTalking 不可用	保留文字回答，前端切换轻量数字人或静态状态
云端或本地 ASR 失败	提示重新录音，游客仍可使用文字输入；不把本地路线静默切换到云端
云端或本地 TTS 失败	保留文字回答并提示播报不可用，不影响游客继续查看回答
情绪模型失败	记录失败状态并使用文本倾向，不影响问答
GPS 不可用	使用景点码或手动选择位置
路线景区无可核验点位	/v1/recommend 返回 422，前端提示暂时无法生成地图路线
高德底图不可用	显示底图加载失败提示，保留路线顺序、文字行程和高德分段导航链接
GPU 不足	选择其他空闲卡；无法分配时返回可恢复错误

4.5 个性化地图路线设计


- /v1/location/options 只把景点目录中能够与定位锚点匹配的条目作为 map_points 发布，并为每个点保留 coordinate_system、survey_status、source、source_url 和 estimated_accuracy_m。
- 路线规划器按 scenic_area 过滤点位，优先使用游客选择或已确认的 start_spot_id；未指定时从景区默认入口点开始。起点缺少坐标时回退到默认点并返回警告。
- 规划器在 90–480 分钟预算内迭代选择站点，最多 8 站。候选评分综合兴趣匹配、景点优先级、亲子/长者适配、无障碍友好度和距上一站的距离；“无障碍优先”会排除低通行友好度候选。
- 步行距离采用 WGS-84 球面距离乘 1.22 道路折算系数；正常、少走路和无障碍偏好分别按 72、55、48 米/分钟估算步行时间。上述数值用于路线比较和时间预算，不是实测轨迹。
- 接口保留每站的 WGS-84 来源坐标，同时返回转换后的 map_lat/map_lng（GCJ-02）、站点 顺序、预计停留/步行时间、推荐理由、警告、地图覆盖率和高德分段步行导航链接；map 元数据 标记 coordinate_system=WGS-84、display_coordinate_system=GCJ-02 和 navigation_provider=amap。
- 前端用 Leaflet 加载高德在线底图，并使用 GCJ-02 坐标绘制编号标记和虚线；虚线仅表示访问 顺序，不执行园内道路寻路。高德底图失败时保留文字行程和导航入口。

5. 数据设计

5.1 实体关系

核心数据 ER 图

SQLite 实体、逻辑会话键与历史数据导入关系



session_id 是应用层逻辑会话键；标记为 AK*、FK* 的字段由应用层维护关联， 当前 SQLite 未声明外键约束。

5.2 核心数据表

数据表	主键	用途
chat_logs	id	保存用户与助手消息、元数据和时间
feedback	id	保存景点评分、意见和倾向
emotion_events	id	保存情绪任务、结果、模式和错误
avatar_settings	固定 id=1	保存当前数字人配置
attractions	id	保存景区与子景点目录

数据表	主键	用途
tourism_visits	id	保存历史游客访问事实
dataset_imports	source_file	保存历史数据导入版本和行数

5.3 知识库数据

景区文档按标题和段落切片，BGE-M3 生成 1024 维归一化向量，FAISS IndexFlatIP 执行相似度检索。每个片段保留来源、标题和片段 ID，回答返回引用信息。管理员文档和 官方资料分开管理，索引重建成功后再替换当前索引。

5.4 地图与路线数据

地图锚点来自 services/api/app/location.py 的默认来源点位，或生产环境的 data/lingshan/location_points.json。默认目录包含 9 个公开资料近似 WGS-84 点位；正式上线后应替换为景区审核或现场实测点。路线是按请求即时计算的派生结果，不新建数据库表，也不保存游客兴趣、同行人群和步行偏好。浏览器定位确认后，路线请求只携带景点编号作为起点，不重复传送手机原始经纬度。部分默认锚点的来源链接指向 OpenStreetMap，该信息只用于点位来源 追溯；当前底图和外部导航服务均为高德地图。

6. 接口设计

6.1 公开接口

方法	路径	说明
POST	/v1/chat	文字问答；支持普通 JSON 或 SSE 流式响应
POST	/v1/asr	上传录音；按 model_route 调用云端 GLM-ASR 或本地 FunASR，返回识别文本、语音提供方和情绪任务 ID
POST	/v1/tts	按 model_route 调用云端或本地 GLM-TTS，将文本合成为 WAV
POST	/v1/vision/guide	图片识别并结合 RAG 生成景点讲解
POST	/v1/recommend	接收景区、时长、多选兴趣、人群、步行偏好和起点，返回地图化个性路线
POST	/v1/locate	解析 GPS、景点码或手动位置
GET	/v1/location/options	返回景点目录、可绘制地图点位、坐标来源、覆盖数和定位降级说明
GET	/v1/map/tiles/{z}/{x}/{y}.png	旧版 OSM 同源瓦片代理兼容接口；当前游客路线页不调用
POST	/v1/feedback	提交景点评分和建议
POST	/v1/livetalking/offer	建立数字人 WebRTC 会话
POST	/v1/livetalking/heartbeat	保持数字人会话并检测页面活跃状态
POST	/v1/livetalking/close	关闭会话并触发资源释放

6.2 管理接口

方法	路径	说明
POST	/v1/admin/auth/login	管理员登录
POST	/v1/admin/auth/logout	注销管理会话
GET/POST/DELETE	/v1/admin/kb/documents	查看、上传和删除知识文档
GET/PUT	/v1/admin/avatar	查询和更新数字人配置
GET	/v1/admin/analytics/overview	查询实时运营概览
GET	/v1/admin/analytics/historical	查询历史游客分析
GET	/v1/admin/emotion/status	查询情绪任务统计

6.3 流式事件

/v1/chat 的 SSE 响应包含 meta、delta、done 和 error 事件。meta 提供会话、引用和数字人反应；delta 提供增量文本；done 提供总延迟；error 提供可显示错误。

7. 部署设计

当前比赛演示环境暂时采用“本地 GPU 计算节点 + 华为云公网转发节点”的两级部署：核心服务运行在一台配备 4 张 NVIDIA RTX 3090 的本地服务器上，承担 Qwen 大模型、RAG、FunASR、本地 GLM-TTS、数字人和多模态情感分析等计算；华为云服务器仅作为公网入口，转发游客端、管理后台、HTTPS 与 WebRTC/TURN 流量，不承担模型推理。该拓扑属于当前演示部署方式，并非系统运行的固定硬件要求，后续可迁移至景区私有服务器或云端 GPU 环境。

7.1 服务与端口

服务	端口	暴露范围
游客 HTTP/API	8001	游客与接口调用方
游客 HTTPS + TURN/TCP	8443	麦克风与 WebRTC 公网入口
LiveTalking	8010	仅内部
RAG	8020	仅本机
完整本地 Qwen3-8B	8021	仅本机，按需加载
轻量本地 Qwen3-1.7B	8022	仅本机，按需加载
FunASR 与本地语音网关	8030	仅本机
本地开源 GLM-TTS	8031	仅本机
管理后台	8444	管理员

7.2 启动方式

```
cd /home/gmn/codes/cup
bash deploy/start_livetalking.sh
bash deploy/start_api.sh
```

`start_api.sh` 会检查并启动 8030 本地语音网关；当前 `systemd` 部署通过 `cup-local-speech.service` 依赖 `cup-glm-tts.service`，使 8031 本地 GLM-TTS 同步就绪。两条 Qwen 路线的 ASR/TTS 均通过上述本机服务完成，不调用云端语音 API。

地图前端不新增服务端端口或 GPU 进程。Leaflet JavaScript/CSS 位于 `services/api/static/vendor/`；高德在线底图和高德 URI 分段导航由游客浏览器直接访问，依赖 客户端外网。地图底图不可用不会阻塞 `/v1/recommend` 的路线计算和文字结果。

7.3 地图资源与网络依赖

- Leaflet 静态资源随游客端部署，不从 CDN 动态加载。
- 当前底图地址由路线接口的 `map.tile_url` 提供，指向高德地图瓦片服务；页面保留“© 高德地图”署名。点击逐站“步行导航”后访问 `https://uri.amap.com/navigation`，参数使用 GCJ-02、步行模式。
- 客户端网络或 WebView 白名单需允许 `webird01-04.is.autonavi.com` 和 `uri.amap.com` 的 HTTPS 请求；生产环境应根据访问规模、授权与合规要求确认高德地图服务的接入方式。
- 旧版 OSM 代理仍保留 `/v1/map/tiles/`、`MAP_TILE_UPSTREAM_PROXY` 和 `data/lingshan/map_tile_cache/`，但不在当前路线页主链路中；计划移除时应同步删除接口、配置、缓存与相关测试。
- 外网不可用时不得阻塞 `/v1/recommend`；前端应保留逐站文本、坐标、警告和导航链接。
- 不执行整区预取、离线下载或并发批量抓取；生产环境高流量使用在线瓦片前，应评估专用地图 服务；不得移除数据署名。

7.4 GPU 生命周期

- LiveTalking 在页面建立 WebRTC 会话后选择 0-3 号 GPU 中的空闲卡。
- 页面关闭或心跳超时后停止数字人 GPU 进程。
- RAG embedding 使用 CPU 常驻协调器和按需 GPU worker。
- RAG worker 连续请求复用，空闲 180 秒后退出并释放 CUDA 上下文。
- FunASR 常驻 CPU 内存，避免与 Qwen、数字人和情绪模型争用显存。
- 本地 GLM-TTS 使用独立进程，启动时从候选 GPU 中选择满足显存门槛的空闲卡；加载或推理失败时返回明确错误。
- 完整 Qwen3-8B 与轻量 Qwen3-1.7B 使用独立服务，只在选择对应路线时动态选卡和加载；无满足条件 GPU 或真实 CUDA OOM 会向游客端返回明确错误。

7.5 安全要求

- 麦克风访问使用 HTTPS 或 localhost 安全上下文。
- 管理后台使用签名会话 Cookie 和请求来源校验。
- RAG、LiveTalking 与模型密钥不直接暴露给游客端。
- 上传文件校验扩展名、大小和保存路径，禁止路径穿越。
- 多模态原始媒体默认在分析后删除，只保留结构化结果。
- 路线规划只接受目录内景点编号作为起点；外部导航链接使用固定高德 URI 域名、GCJ-02 经纬度 和步行模式参数生成，前端以新窗口和 `noopener noreferrer` 打开。

- WGS-84→GCJ-02 转换在服务端完成，浏览器不接收第三方地图密钥。旧版瓦片代理若继续保留， 仍需限制缩放级别、x/y 范围、固定上游、响应类型和大小，防止路径穿越和任意 URL 代理。

8. 测试与验收

8.1 测试层次

层次	内容
单元测试	文档切片、向量检索、会话、语义分段、鉴权、数据聚合、地图点位过滤和路线预算
接口测试	问答、云端/本地 ASR、云端/本地 TTS、视觉、定位、路线输入/输出、反馈、管理和数字人接口
集成测试	分别验证云端 GLM 与两条 Qwen 路线的 ASR→RAG→TTS→LiveTalking 完整链路
稳定性测试	服务重启、模型失败、页面关闭、高德底图失败、心跳超时和 GPU 回收
安全测试	未登录管理访问、非法上传、超大请求和密钥泄露检查

8.2 验收条件

项目	条件
知识问答	标准事实题准确率不低于 90%，回答提供知识引用
语音链路	热链路在 5 秒目标内开始非静音数字人播报
路线一致性	选择 Qwen3-1.7B 或 Qwen3-8B 后，ASR 提供方为本地 FunASR，TTS 提供方为本地 GLM-TTS，不调用云端语音接口
降级能力	RAG、ASR、数字人或情绪模型失败时有明确反馈
管理隔离	未登录用户不能访问知识、配置和运营管理接口
资源释放	页面无活动或 worker 空闲后，相关 GPU 推理进程退出
数据真实性	无评分或无情绪结果时显示“暂无”，不得生成虚假指标
地图路线	灵山与拈花湾均能按条件生成路线；站点不超预算和 8 站，点位保留来源与覆盖说明
地图降级	禁止高德瓦片访问后仍能查看逐站行程和导航入口，页面明确说明顺序线不是道路导航

9. 维护与约束

9.1 当前约束

- 云端 GLM 路线的问答、ASR、TTS 及视觉识别依赖公网；两条 Qwen 路线的问答、ASR 和 TTS 均在本地服务器运行，语音主链路不依赖云端 API，但需要本地 CPU、内存、GPU 和模型文件可用。
- 当前数字人使用已安装头像模型；新增外观需要制作新的模型资源。
- GPS、Wi-Fi 和二维码定位属于适配接口，生产部署需接入真实位置服务。

- 当前地图仅覆盖具备来源坐标的部分景点，路线顺序线不沿园内道路；步行时间为估算值，且未接入实时客流、开放状态、演出时刻或施工绕行。
- 高德底图和分段导航依赖公网；正式商用前应根据景区授权点位、访问规模和合规要求确认地图服务授权及接入方案。OpenStreetMap 仅保留为部分公开近似点位的数据来源和旧版兼容链路。
- 高并发部署需要增加 GPU 配额、会话队列、限流和容量测试。
- 维护时同步更新接口文档并执行知识库回归，定期检查日志、数据导入和服务健康状态。