

灵山小向导·灵曦——软件工程文档

项目名称：景区导览服务 AI 数字人系统

文档类型：软件需求与设计说明

文档版本：V1.1

更新日期：2026-07-20

目录

1. 文档概述

2. 系统概述

3. 需求分析

4. 系统设计

5. 数据设计

6. 接口设计

7. 部署设计

8. 测试与验收

9. 维护与约束

1. 文档概述

1.1 编写目的

本文档说明“灵山小向导·灵曦”的软件需求、系统架构、核心流程、数据结构、接口、部署和测试方案，作为开发、联调、测试与后续维护的统一依据。

1.2 系统范围

系统包含游客端、景区管理端、导览 API、RAG 服务、语音与视觉模型接口、数字人服务、情绪分析服务和本地数据存储。系统不负责票务交易、真实地图导航和景区硬件控制。

1.3 术语

术语	说明
RAG	检索增强生成，先检索景区资料，再生成回答
ASR / TTS	语音识别 / 语音合成
SSE	服务端事件，用于流式返回模型文本
WebRTC	数字人实时音视频传输协议
LiveTalking	数字人口型驱动与音视频服务
HumanOmni	音视频情绪分析模型

2. 系统概述

2.1 建设目标

系统为游客提供文字问答、语音问答、数字人讲解、路线推荐、拍照识景、定位辅助和满意度反馈；为景区管理人员提供知识维护、数字人配置、服务统计和游客感受度分析。

2.2 用户角色

角色	主要职责
游客	提问、听取讲解、查询路线、识别景点、提交反馈
内容管理员	维护景区知识文档并重建索引
运营管理员	查看访问量、热门咨询、响应时间和游客反馈
系统维护人员	启停服务、检查健康状态、管理 GPU 与日志

2.3 系统边界

- 游客端只能访问公开导览接口，不能直接访问管理接口。
- 管理端使用独立登录会话和来源校验。
- RAG 与 LiveTalking 只作为内部服务，由 FastAPI 网关调用。
- GLM 模型通过服务端 API 调用，密钥不下发到浏览器。
- 知识库回答只以已导入的景区资料为事实依据。

3. 需求分析


3.1 功能需求

编号	模块	功能要求
FR-01	景区问答	支持文字提问、连续追问、引用来源和资料不足时拒答
FR-02	语音交互	浏览器录音后完成 ASR，并进入统一问答流程
FR-03	数字人讲解	将回答按完整语义句合成语音并驱动口型，通过 WebRTC 播放
FR-04	路线推荐	根据兴趣、时间和当前位置生成游览路线
FR-05	拍照识景	视觉模型识别图片，再由景区知识库校准讲解
FR-06	定位辅助	支持 GPS、景点码和手动选择，并在定位失败时降级
FR-07	游客反馈	对具体景区或景点提交 1-5 分和文字建议
FR-08	管理登录	管理员登录、会话验证和退出
FR-09	知识管理	上传、查看、删除管理员文档并触发索引重建
FR-10	数字人配置	配置显示名称、已安装形象、音色和默认表情
FR-11	运营分析	展示游客量、问答量、响应时间、热门主题和反馈
FR-12	感受度分析	保存情绪、文本倾向、方面、置信度和分析状态

3.2 非功能需求

编号	类别	要求
NFR-01	性能	热链路语音问答目标为 5 秒内开始数字人非静音播报
NFR-02	可用性	RAG、数字人或情绪模型失败时应明确提示或降级，不阻塞基础问答
NFR-03	安全	管理接口鉴权；模型密钥仅在服务端保存；限制文件类型和大小
NFR-04	可维护性	API、RAG、数字人和分析模块独立部署，提供健康检查
NFR-05	资源	GPU 模型按需启用，空闲后释放 CUDA 上下文
NFR-06	可追溯性	回答记录引用片段、响应时间、模型路线和会话标识

3.3 系统用例图




3.4 主要用例

用例	前置条件	主流程	异常处理
景区问答	游客端可访问 API	提交问题→检索知识→流式生成→展示引用	RAG 不可用时返回明确错误
语音数字人问答	HTTPS 麦克风授权成功	录音→ASR→RAG→TTS→数字人口型→WebRTC 播放	数字人不可用时回退文字或轻量模式
知识库更新	管理员已登录	上传文档→校验→切片→向量化→重建索引	文件不合法或重建失败时保留旧索引
运营分析	管理员已登录	查询日志、反馈、情绪和历史数据→聚合展示	数据不足时显示“暂无”

4. 系统设计

4.1 总体架构

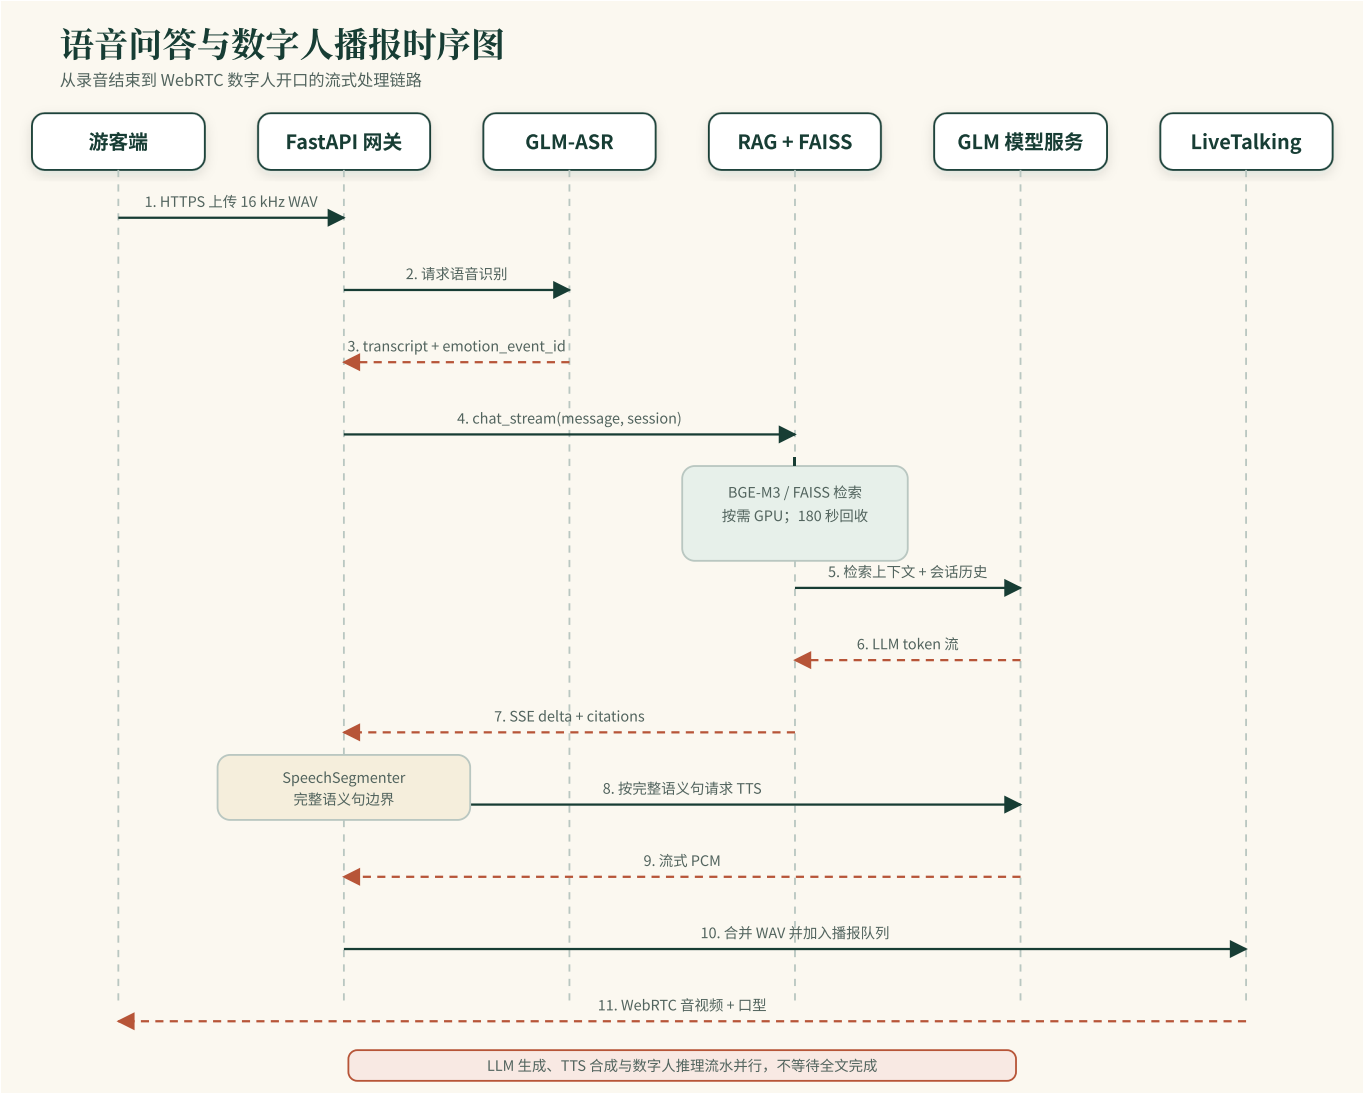


系统采用分层服务架构。FastAPI 负责对外接口和业务编排；RAG、GLM 多模态、LiveTalking 和 HumanOmni 作为独立服务；SQLite、FAISS、文档和模型资源分别管理。

4.2 模块划分

模块	代码位置	职责
导览 API	services/api/app/	会话、问答、语音、视觉、路线、定位、反馈和管理接口
RAG 服务	llm/api.py 、 llm/rag/	文档切片、向量检索、提示构建、会话和模型生成
数字人服务	LiveTalking/	会话管理、音频队列、口型推理和 WebRTC 输出
情绪分析	services/emotion/	音视频情绪推理、文本降级和结构化结果
管理前端	services/api/static/	登录、知识管理、数字人设置和数据展示
部署脚本	deploy/	服务启动、TLS、TURN 和公网转发

4.3 语音问答时序



模型回答采用 SSE 流式返回。FastAPI 使用语义边界切分完整句子，并行衔接 TTS 和 LiveTalking，避免等待全文完成。新问题到达时取消旧播报队列，防止音频重叠。

4.4 异常与降级


故障	系统处理
RAG 服务不可用	返回 503 和明确错误，不生成无知识依据的答案
LiveTalking 不可用	保留文字回答，前端切换轻量数字人或静态状态
ASR 失败	提示重新录音，游客仍可使用文字输入
情绪模型失败	记录失败状态并使用文本倾向，不影响问答
GPS 不可用	使用景点码或手动选择位置
GPU 不足	选择其他空闲卡；无法分配时返回可恢复错误

5. 数据设计

5.1 实体关系

核心数据 ER 图

SQLite 实体、逻辑会话键与历史数据导入关系



session_id 是应用层逻辑会话键；标记为 AK*、FK* 的字段由应用层维护关联，当前 SQLite 未声明外键约束。

5.2 核心数据表

数据表	主键	用途
chat_logs	id	保存用户与助手消息、元数据和时间
feedback	id	保存景点评分、意见和倾向
emotion_events	id	保存情绪任务、结果、模式和错误
avatar_settings	固定 id=1	保存当前数字人配置
attractions	id	保存景区与子景点目录
tourism_visits	id	保存历史游客访问事实
dataset_imports	source_file	保存历史数据导入版本和行数

5.3 知识库数据

景区文档按标题和段落切片，BGE-M3 生成 1024 维归一化向量，FAISS `IndexFlatIP` 执行相似度检索。每个片段保留来源、标题和片段 ID，回答返回引用信息。管理员文档和 官方资料 分开管理，索引重建成功后再替换当前索引。

6. 接口设计

6.1 公开接口

方法	路径	说明
POST	/v1/chat	文字问答；支持普通 JSON 或 SSE 流式响应
POST	/v1/asr	上传录音并返回识别文本和情绪任务 ID
POST	/v1/tts	将文本合成为 WAV
POST	/v1/vision/guide	图片识别并结合 RAG 生成景点讲解
POST	/v1/recommend	生成个性化游览路线
POST	/v1/locate	解析 GPS、景点码或手动位置
POST	/v1/feedback	提交景点评分和建议
POST	/v1/livetalking/offer	建立数字人 WebRTC 会话
POST	/v1/livetalking/heartbeat	保持数字人会话并检测页面活跃状态
POST	/v1/livetalking/close	关闭会话并触发资源释放

6.2 管理接口

方法	路径	说明
POST	/v1/admin/auth/login	管理员登录
POST	/v1/admin/auth/logout	注销管理会话
GET/POST/DELETE	/v1/admin/kb/documents	查看、上传和删除知识文档
GET/PUT	/v1/admin/avatar	查询和更新数字人配置
GET	/v1/admin/analytics/overview	查询实时运营概览
GET	/v1/admin/analytics/historical	查询历史游客分析
GET	/v1/admin/emotion/status	查询情绪任务统计

6.3 流式事件

/v1/chat 的 SSE 响应包含 meta、delta、done 和 error 事件。meta 提供会话、引用和数字人反应；delta 提供增量文本；done 提供总延迟；error 提供可显示错误。

7. 部署设计

7.1 服务与端口

服务	端口	暴露范围
游客 HTTP/API	8001	游客与接口调用方
游客 HTTPS + TURN/TCP	8443	麦克风与 WebRTC 公网入口
LiveTalking	8010	仅内部
RAG	8020	仅本机
管理后台	8444	管理员

7.2 启动方式

```
cd /home/gmn/codes/cup
bash deploy/start_livetalking.sh
bash deploy/start_api.sh
```

7.3 GPU 生命周期

- LiveTalking 在页面建立 WebRTC 会话后选择 0-3 号 GPU 中的空闲卡。
- 页面关闭或心跳超时后停止数字人 GPU 进程。
- RAG embedding 使用 CPU 常驻协调器和按需 GPU worker。
- RAG worker 连续请求复用，空闲 180 秒后退出并释放 CUDA 上下文。
- 本地大模型只在选择本地模型路线时加载。

7.4 安全要求

- 麦克风访问使用 HTTPS 或 localhost 安全上下文。
- 管理后台使用签名会话 Cookie 和请求来源校验。
- RAG、LiveTalking 与模型密钥不直接暴露给游客端。
- 上传文件校验扩展名、大小和保存路径，禁止路径穿越。
- 多模态原始媒体默认在分析后删除，只保留结构化结果。

8. 测试与验收

8.1 测试层次

层次	内容
单元测试	文档切片、向量检索、会话、语义分段、鉴权和数据聚合
接口测试	问答、ASR、TTS、视觉、定位、反馈、管理和数字人接口
集成测试	ASR→RAG→TTS→LiveTalking 完整链路
稳定性测试	服务重启、模型失败、页面关闭、心跳超时和 GPU 回收
安全测试	未登录管理访问、非法上传、超大请求和密钥泄露检查

8.2 验收条件

项目	条件
知识问答	标准事实题准确率不低于 90%，回答提供知识引用
语音链路	热链路在 5 秒目标内开始非静音数字人播报
降级能力	RAG、ASR、数字人或情绪模型失败时有明确反馈
管理隔离	未登录用户不能访问知识、配置和运营管理接口
资源释放	页面无活动或 worker 空闲后，相关 GPU 推理进程退出
数据真实性	无评分或无情绪结果时显示“暂无”，不得生成虚假指标

9. 维护与约束

9.1 当前约束

- 默认问答、语音和视觉依赖 GLM 云端模型，公网波动会影响时延。
- 当前数字人使用已安装头像模型；新增外观需要制作新的模型资源。
- GPS、Wi-Fi 和二维码定位属于适配接口，生产部署需接入真实位置服务。
- 高并发部署需要增加 GPU 配额、会话队列、限流和容量测试。
- 维护时同步更新接口文档并执行知识库回归，定期检查日志、数据导入和服务健康状态。