

灵山小向导·灵曦——软件工程文档

项目名称：景区导览服务 AI 数字人系统

文档类型：软件需求与设计说明

更新日期：2026-07-20

1. 文档概述

1.1 编写目的

本文档说明“灵山小向导·灵曦”的软件需求、系统架构、核心流程、数据结构、接口、部署和测试方案，作为开发、联调、测试与后续维护的统一依据。

1.2 系统范围

系统包含游客端、景区管理端、导览 API、RAG 服务、语音与视觉模型接口、数字人服务、情绪分析服务和本地数据存储。系统不负责票务交易、真实地图导航和景区硬件控制。

1.3 术语

术语	说明
RAG	检索增强生成，先检索景区资料，再生成回答
ASR / TTS	语音识别 / 语音合成
SSE	服务端事件，用于流式返回模型文本
WebRTC	数字人实时音视频传输协议
LiveTalking	数字人口型驱动与音视频服务
HumanOmni	音视频情绪分析模型

2. 系统概述

2.1 建设目标

系统为游客提供文字问答、语音问答、数字人讲解、路线推荐、拍照识景、定位辅助和 满意度反馈；为景区管理人员提供知识维护、数字人配置、服务统计和游客感受度分析。

2.2 用户角色

角色	主要职责
游客	提问、听取讲解、查询路线、识别景点、提交反馈
内容管理员	维护景区知识文档并重建索引
运营管理员	查看访问量、热门咨询、响应时间和游客反馈
系统维护人员	启停服务、检查健康状态、管理 GPU 与日志

2.3 系统边界

- 游客端只能访问公开导览接口，不能直接访问管理接口。
- 管理端使用独立登录会话和来源校验。
- RAG 与 LiveTalking 只作为内部服务，由 FastAPI 网关调用。
- GLM 模型通过服务端 API 调用，密钥不下发到浏览器。
- 知识库回答只以已导入的景区资料为事实依据。

3. 需求分析


3.1 功能需求

编号	模块	功能要求
FR-01	景区问答	支持文字提问、连续追问、引用来源和资料不足时拒答
FR-02	语音交互	浏览器录音后完成 ASR，并进入统一问答流程
FR-03	数字人讲解	将回答按完整语义句合成语音并驱动口型，通过 WebRTC 播放
FR-04	路线推荐	根据兴趣、时间和当前位置生成游览路线
FR-05	拍照识景	视觉模型识别图片，再由景区知识库校准讲解
FR-06	定位辅助	支持 GPS、景点码和手动选择，并在定位失败时降级
FR-07	游客反馈	对具体景区或景点提交 1-5 分和文字建议
FR-08	管理登录	管理员登录、会话验证和退出
FR-09	知识管理	上传、查看、删除管理员文档并触发索引重建
FR-10	数字人配置	配置显示名称、已安装形象和合成声音；表情由情绪策略实时驱动
FR-11	运营分析	展示游客量、问答量、响应时间、热门主题和反馈
FR-12	感受度分析	保存情绪、文本倾向、方面、置信度和分析状态

3.2 非功能需求

编号	类别	要求
NFR-01	性能	热链路语音问答目标为 5 秒内开始数字人非静音播报
NFR-02	可用性	RAG、数字人或情绪模型失败时应明确提示或降级，不阻塞基础问答
NFR-03	安全	管理接口鉴权；模型密钥仅在服务端保存；限制文件类型和大小
NFR-04	可维护性	API、RAG、数字人和分析模块独立部署，提供健康检查
NFR-05	资源	GPU 模型按需启用，空闲后释放 CUDA 上下文
NFR-06	可追溯性	回答记录引用片段、响应时间、模型路线和会话标识

3.3 系统用例图




3.4 主要用例

用例	前置条件	主流程	异常处理
景区问答	游客端可访问 API	提交问题→检索知识→流式生成→展示引用	RAG 不可用时返回明确错误
语音数字人问答	HTTPS 麦克风授权成功	录音→ASR→RAG→TTS→数字人口型→WebRTC 播放	数字人不可用时回退文字或轻量模式
知识库更新	管理员已登录	上传文档→校验→切片→向量化→重建索引	文件不合法或重建失败时保留旧索引
运营分析	管理员已登录	查询日志、反馈、情绪和历史数据→聚合展示	数据不足时显示“暂无”

4. 系统设计

4.1 总体架构

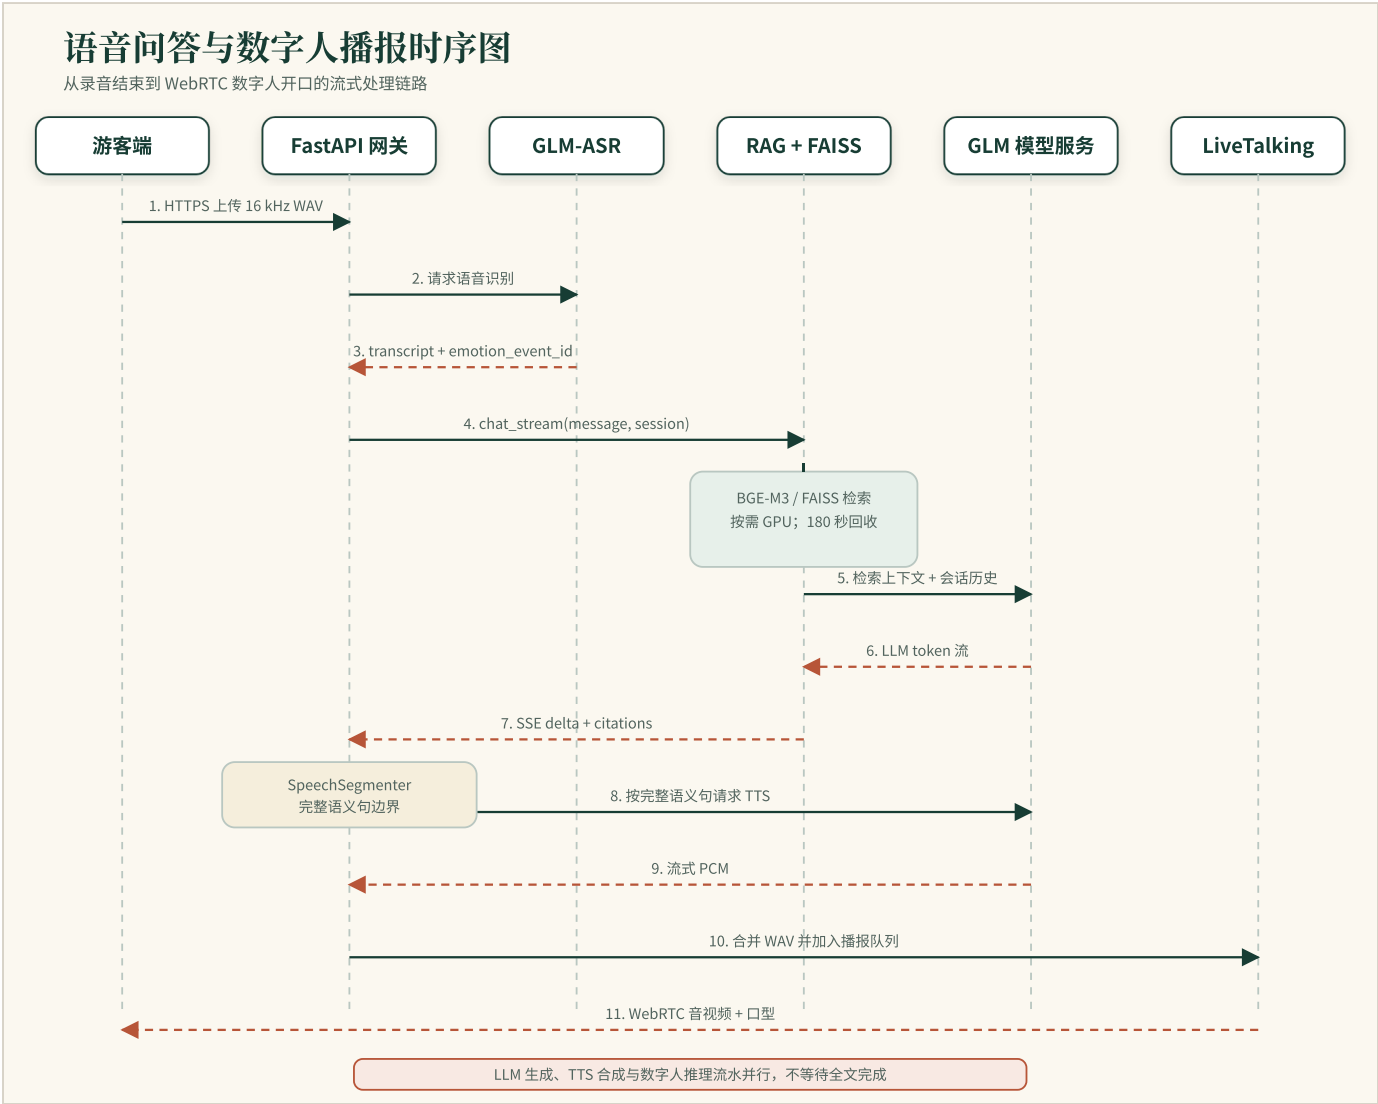


系统采用分层服务架构。FastAPI 负责对外接口和业务编排；RAG、GLM 多模态、LiveTalking 和 HumanOmni 作为独立服务；SQLite、FAISS、文档和模型资源分别管理。

4.2 模块划分

模块	代码位置	职责
导览 API	<code>services/api/app/</code>	会话、问答、语音、视觉、路线、定位、反馈和管理接口
RAG 服务	<code>llm/api.py</code> 、 <code>llm/rag/</code>	文档切片、向量检索、提示构建、会话和模型生成
数字人服务	<code>LiveTalking/</code>	会话管理、音频队列、口型推理和 WebRTC 输出
情绪分析	<code>services/emotion/</code>	音视频情绪推理、文本降级和结构化结果
管理前端	<code>services/api/static/</code>	登录、知识管理、数字人设置和数据展示
部署脚本	<code>deploy/</code>	服务启动、TLS、TURN 和公网转发

4.3 语音问答时序



模型回答采用 SSE 流式返回。FastAPI 使用语义边界切分完整句子，并行衔接 TTS 和 LiveTalking，避免等待全文完成。新问题到达时取消旧播报队列，防止音频重叠。

4.4 异常与降级

故障	系统处理
RAG 服务不可用	返回 503 和明确错误，不生成无知识依据的答案
LiveTalking 不可用	保留文字回答，前端切换轻量数字人或静态状态
ASR 失败	提示重新录音，游客仍可使用文字输入
情绪模型失败	记录失败状态并使用文本倾向，不影响问答
GPS 不可用	使用景点码或手动选择位置
GPU 不足	选择其他空闲卡；无法分配时返回可恢复错误

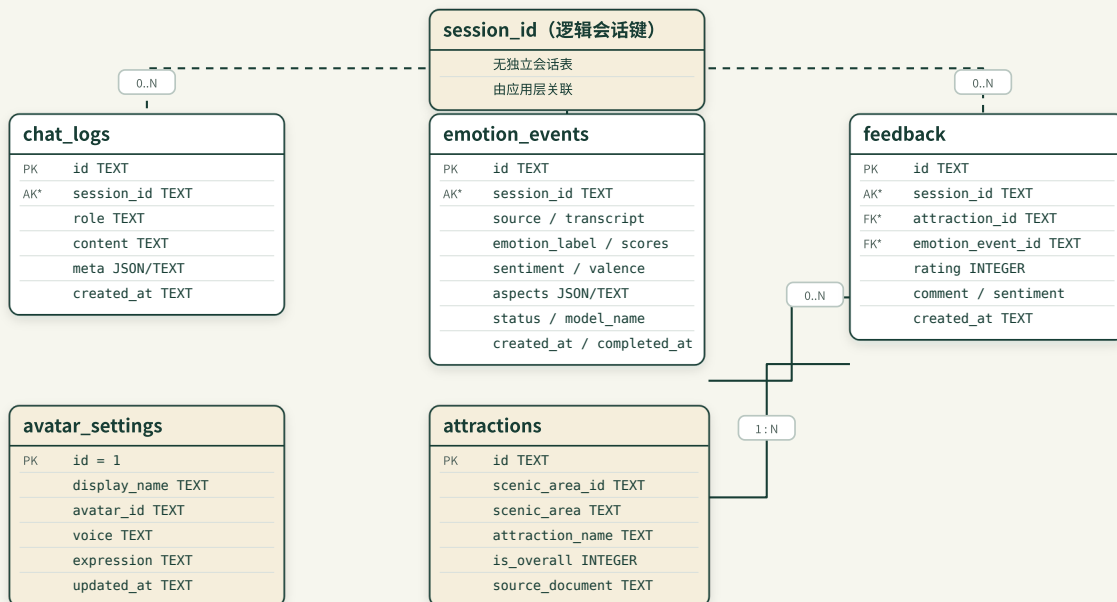
5. 数据设计

5.1 实体关系


核心数据 ER 图

SQLite 实体、逻辑会话键与历史数据导入关系

实时交互与运营数据



赛题历史游客数据



AK* / FK* 表示应用层关联；当前 SQLite 未声明 FOREIGN KEY 约束

session_id 是应用层逻辑会话键；标记为 **AK***、**FK*** 的字段由应用层维护关联，当前 SQLite 未声明外键约束。

5.2 核心数据表

数据表	主键	用途
chat_logs	id	保存用户与助手消息、元数据和时间
feedback	id	保存景点评分、意见和倾向
emotion_events	id	保存情绪任务、结果、模式和错误
avatar_settings	固定 id=1	保存当前数字人配置
attractions	id	保存景区与子景点目录
tourism_visits	id	保存历史游客访问事实
dataset_imports	source_file	保存历史数据导入版本和行数

5.3 知识库数据

景区文档按标题和段落切片，BGE-M3 生成 1024 维归一化向量，FAISS IndexFlatIP 执行相似度检索。每个片段保留来源、标题和片段 ID，回答返回引用信息。管理员文档和 官方资料分开管理，索引重建成功后再替换当前索引。

6. 接口设计

6.1 公开接口

方法	路径	说明
POST	/v1/chat	文字问答；支持普通 JSON 或 SSE 流式响应
POST	/v1/asr	上传录音并返回识别文本和情绪任务 ID
POST	/v1/tts	将文本合成为 WAV
POST	/v1/vision/guide	图片识别并结合 RAG 生成景点讲解
POST	/v1/recommend	生成个性化游览路线
POST	/v1/locate	解析 GPS、景点码或手动位置
POST	/v1/feedback	提交景点评分和建议
POST	/v1/livetalking/offer	建立数字人 WebRTC 会话
POST	/v1/livetalking/heartbeat	保持数字人会话并检测页面活跃状态
POST	/v1/livetalking/close	关闭会话并触发资源释放

6.2 管理接口

方法	路径	说明
POST	/v1/admin/auth/login	管理员登录
POST	/v1/admin/auth/logout	注销管理会话
GET/POST/DELETE	/v1/admin/kb/documents	查看、上传和删除知识文档
GET/PUT	/v1/admin/avatar	查询和更新数字人配置
GET	/v1/admin/analytics/overview	查询实时运营概览
GET	/v1/admin/analytics/historical	查询历史游客分析
GET	/v1/admin/emotion/status	查询情绪任务统计

6.3 流式事件

/v1/chat 的 SSE 响应包含 meta、delta、done 和 error 事件。meta 提供会话、引用和数字人反应；delta 提供增量文本；done 提供总延迟；error 提供可显示错误。

7. 部署设计

当前比赛演示环境暂时采用“本地 GPU 计算节点 + 华为云公网转发节点”的两级部署：核心服务运行在一台配备 4 张 NVIDIA RTX 3090 的本地服务器上，承担大模型、RAG、数字人和多模态情感分析等计算；华为云服务器仅作为公网入口，转发游客端、管理后台、HTTPS 与 WebRTC/TURN 流量，不承担模型推理。该拓扑属于当前演示部署方式，并非系统运行的固定硬件要求，后续可迁移至景区私有服务器或云端 GPU 环境。

7.1 服务与端口

服务	端口	暴露范围
游客 HTTP/API	8001	游客与接口调用方
游客 HTTPS + TURN/TCP	8443	麦克风与 WebRTC 公网入口
LiveTalking	8010	仅内部
RAG	8020	仅本机
管理后台	8444	管理员

7.2 启动方式

```
cd /home/gmn/codes/cup
bash deploy/start_livetalking.sh
bash deploy/start_api.sh
```

7.3 GPU 生命周期

- LiveTalking 在页面建立 WebRTC 会话后选择 0-3 号 GPU 中的空闲卡。
- 页面关闭或心跳超时后停止数字人 GPU 进程。
- RAG embedding 使用 CPU 常驻协调器和按需 GPU worker。
- RAG worker 连续请求复用，空闲 180 秒后退出并释放 CUDA 上下文。
- 完整 Qwen2-7B 与轻量 Qwen3-1.7B 使用独立服务，只在选择对应路线时动态选卡和加载；无满足条件 GPU 或真实 CUDA OOM 会向游客端返回明确错误。

7.4 安全要求

- 麦克风访问使用 HTTPS 或 localhost 安全上下文。
- 管理后台使用签名会话 Cookie 和请求来源校验。
- RAG、LiveTalking 与模型密钥不直接暴露给游客端。

- 上传文件校验扩展名、大小和保存路径，禁止路径穿越。
- 多模态原始媒体默认在分析后删除，只保留结构化结果。

8. 测试与验收

8.1 测试层次

层次	内容
单元测试	文档切片、向量检索、会话、语义分段、鉴权和数据聚合
接口测试	问答、ASR、TTS、视觉、定位、反馈、管理和数字人接口
集成测试	ASR→RAG→TTS→LiveTalking 完整链路
稳定性测试	服务重启、模型失败、页面关闭、心跳超时和 GPU 回收
安全测试	未登录管理访问、非法上传、超大请求和密钥泄露检查

8.2 验收条件

项目	条件
知识问答	标准事实题准确率不低于 90%，回答提供知识引用
语音链路	热链路在 5 秒目标内开始非静音数字人播报
降级能力	RAG、ASR、数字人或情绪模型失败时有明确反馈
管理隔离	未登录用户不能访问知识、配置和运营管理接口
资源释放	页面无活动或 worker 空闲后，相关 GPU 推理进程退出
数据真实性	无评分或无情绪结果时显示“暂无”，不得生成虚假指标

9. 维护与约束

9.1 当前约束

- 默认问答、语音和视觉依赖 GLM 云端模型，公网波动会影响时延。
- 当前数字人使用已安装头像模型；新增外观需要制作新的模型资源。
- GPS、Wi-Fi 和二维码定位属于适配接口，生产部署需接入真实位置服务。
- 高并发部署需要增加 GPU 配额、会话队列、限流和容量测试。

- 维护时同步更新接口文档并执行知识库回归，定期检查日志、数据导入和服务健康状态。