

第十五届中国软件杯 · A5 赛题

灵山小向导

让灵曦成为每位游客的专属导游

景区导览服务 AI 数字人

多模态交互

可靠 RAG

数字人讲解

运营闭环

参赛学校：[待填写] 团队：[待填写] 指导教师：[待填写]



灵曦

四个行业痛点，必须同时解决

功能完整度 40 分 · 技术创新 30 分 · 体验 20 分 · 文档 10 分

01

导游资源稀缺

旺季供不应求
服务时间受限



7×24 小时数字人

02

信息单向传递

录音内容固定
无法回答个性问题



语音 / 文字 / 图片互动

03

缺乏情感连接

设备冰冷
讲解缺少亲和力



自然语音与口型表情

04

管理反馈盲区

关注点不可量化
服务难持续优化



实时数据与游客洞察

产品不是一个聊天框，而是一条从游客服务到景区决策的数据闭环。

一次游览，形成一条持续优化的体验闭环

游客端负责服务，管理端把每次互动转化为运营依据



游客实时交互

问答 · 位置 · 反馈 · 情绪



运营洞察

热点 · 趋势 · 建议 · 客群



内容与服务优化

知识库 · 路线 · 现场引导



五层架构，把实时体验与运营分析解耦

内部服务最小暴露 · 云端模型可替换 · GPU 按需使用

交互层	游客网页 / Android App / 管理后台
网关层	FastAPI · HTTPS · SSE · WebRTC · 鉴权
AI 编排层	GLM-ASR · GLM-4V · GLM-TTS · RAG/GLM
数字人层	LiveTalking · Wav2Lip FP16 · Live2D 回退
数据洞察层	SQLite · 14 万历史记录 · HumanOmni

- 8001/8443 游客端
- 8010 LiveTalking
- 8020 RAG（仅本机）
- 8444 独立管理端
- 密钥不下发

可靠 RAG：回答有依据，资料不足就拒答

BGE-M3 + FAISS + 景点元数据过滤 + 有界会话历史

01 文档切片

官方 DOCX / TXT /
XLSX
管理员上传资料

02 向量编码

BGE-M3
1024 维归一化向量

03 候选过滤

景点名 / 别名
景区元数据缩小范围

04 FAISS 检索

IndexFlatIP
余弦相似度 Top-K

05 受约束生成

事实必须来自上下文
返回稳定引用或明确拒答

15/15

标准事实题

100%

事实问答准确率

97

当前知识片段

180s

RAG GPU 空闲释放

CPU 常驻协调器 → 检索时选择空闲 GPU → 连续问答复用 → 空闲后 worker 退出并彻底释放 CUDA

首句即说：跨模型流水线压缩用户等待

不等待全文完成，按完整语义句进入 TTS 与口型驱动



再次提问会取消旧播报队列；LiveTalking 不可用时回退 Live2D，文字问答不中断。

多模态与个性化，让导览从“能回答”走向“懂场景”

所有模态最终回到景区知识与游客真实意图

拍照识景

图

GLM-4V 识别后再次进入本地 RAG 校准，降低通用视觉模型的景点幻觉。

分众路线

路

历史、自然、亲子三类偏好，结合时间与位置输出顺路路线和讲解重点。

弱定位降级

位

GPS 不可用时切换景点码、Wi-Fi/ 二维码适配层或手动选择。

游客感受度

感

HumanOmni 七类情绪 + 文本方面 + 显式评分，保留模式、置信度和降级状态。

原则：不把历史满意度伪装成情绪标签；模型不可用时明确显示降级，不阻塞实时问答。

游客端：一个页面完成问答、路线、识景与定位

真实运行界面 · HTTPS 麦克风 · WebRTC 数字人 · 轻量模式自动回退



一问即答

文字与麦克风统一进入同一条问答链路

四类工具

问答 / 路线 / 识景 / 定位

自然讲解

流式语音、口型与情绪状态同步

可用性优先

数字人暂不可用时仍可先提问

管理后台：把真实互动转化为景区运营动作

实时数据、知识维护、数字人配置、游客感受度与历史洞察



热门咨询主题

灵山大佛

117

九龙灌浴

11

路线与定位

11

灵山梵宫

10

五印坛城

10

祥符禅寺

4

智能服务建议

最近 11 次咨询涉及路线或定位，可在入口强化分众路线和二维码定位提示。

176
今日服务游客

235
累计问答

3182
平均响应 ms

140,447
历史游客记录

用可复现数据证明：准确、快速、稳定、可解释

所有数字注明时间、环境和测试口径，不以演示效果代替验证

100%

15/15 标准题

事实准确率

3373ms

低于赛题 5 秒

语音首响

35

全部 passed

API 回归

97

3 类来源

知识片段

评测项	赛题门槛	当前结果	结论
事实问答	≥ 90%	100%	通过
语音问答首响	< 5 秒	3.373 秒	通过
多模态核心模型	至少 1 个	GLM-4V / HumanOmni	通过
本地知识库	必须构建	BGE-M3 + FAISS	通过

七个创新点，最终落到可复制的景区价值

技术不是堆模型，而是围绕准确性、自然度、可用性与运营闭环做取舍

首句即说

跨模型按语义句流水线

视觉校准

识景结果二次进入 RAG

事实追溯

引用、过滤、拒答共同约束

按需 GPU

闲时释放，连续问答复用

弱定位

GPS→ 景点码→手动多级降级

双层洞察

实时互动 + 14 万历史记录

证据化情绪

模态、置信度、降级可解释

规模化路线

01 景区试点

完善 POI、可信证书与现场定位

02 多景区复制

多租户、方言、IP 头像与内容运营

03 边云协同

量化模型、边缘缓存与旺季容量治理

让每位游客拥有专属导游

让每次互动成为运营依据

团队信息（提交前补充）

- 队长 / 产品架构：[姓名]
- 大模型与 RAG：[姓名]
- 数字人与语音：[姓名]
- 前后端与数据：[姓名]
- 指导教师：[姓名]

答辩现场建议

- 现场语音提问并展示引用与口型
- 演示路线、识景、定位与反馈
- 刷新后台证明真实数据闭环
- 最后展示 15/15 与 3373ms 测试证据

谢谢 · Q&A